Bitácora de Desarrollo Asistido: Tarea 7.2

Araceli Castillo

Maestría en Inteligencia Artificial, Atlantis University

MAI 540: Machine Learning

Prof. Kevin A. García Gallardo

15 de octubre de 2026

Bitácora de Desarrollo Asistido: Tarea 7.2

Herramienta: Claude (Anthropic), con acceso a mis carpetas del Escritorio. Trabajé sobre el mismo repositorio de la Tarea 7.1, *aplicacion-hibrida-mai540*.

Las Instrucciones que Di

Le entregué el enunciado de la tarea y le pedí continuar desde el proyecto de la Tarea 7.1. Le pedí que los textos del modelo de lenguaje fueran reales, generados en mi computadora, y no ejemplos inventados, y que las reglas nuevas se probaran contra esos mismos textos.

Decisiones que Tomó la Herramienta

El modelo de lenguaje no se podía descargar en el entorno de la herramienta, y en mi Mac no estaba instalado. La herramienta escribió un script que creó un entorno con Python 3.12, instaló las dependencias, descargó Qwen2.5-0.5B-Instruct y ejecutó *main.py* sobre 12 solicitudes; yo lo ejecuté en mi Terminal. Amplió *main.py* para guardar cada texto en *resultados/explicaciones.json*, de modo que el antes y el después se midieran sobre exactamente los mismos textos, sin regenerarlos. Eligió medir los falsos positivos con los 200 textos de respaldo, porque se arman solo con datos y son correctos por construcción. Para mostrar que cada prueba falla sin su regla, ejecutó las pruebas nuevas con el verificador de clase recuperado de un commit anterior.

Lo que Corrigió

Al escribir las pruebas apareció un falso positivo: la regla de tono medio rechazaba «un riesgo medio, no alto» porque contiene «alto». Se corrigió para ignorar los extremos precedidos de «no», «no es» o «ni», y la prueba quedó en el repositorio; la evidencia muestra que fallaba antes del ajuste. También se usaron límites de palabra desde el principio, porque sin ellos «bajo» coincidiría dentro de «trabajo», un error que la regla de clase sí tiene. Se descartó «solo» como rasgo inventado, porque el modelo lo usa como adverbio («solo 26 %»).

Qué Verifiqué

Que las cuatro pruebas de las reglas fallan con el verificador de clase y pasan con el nuevo, y que las cinco pruebas originales siguen pasando (13 en total). Que la tabla de rechazos (5 de 12 antes y 10 de 12 después) se reproduce con *medir_rechazos.py*. Leí uno por uno los 12 textos: los dos que siguen pasando tienen afirmaciones dudosas («euros», «situación financiera sostenible») y lo declaro como límite. Que la comparación de modelos usa la misma partición que el predictor. Una diferencia que dejo escrita: las probabilidades del predictor varían hasta un punto entre mi Mac y el entorno de la herramienta (por ejemplo, 0.255 frente a 0.265 en la primera solicitud), por diferencias de versión de pandas y de procesador. Por eso las cifras de los textos son las de mi Mac.

Qué Aprendí

Que un texto puede tener todos los números correctos y aun así contradecir los datos: «sin saldo negativo» no tiene ningún número que el verificador de clase pudiera marcar. Que un verificador que rechaza más no es necesariamente mejor: dos de los rechazos nuevos dependen de dónde puse la franja media. Y que las reglas cierran los huecos que ya vi, pero no los que el modelo todavía no ha inventado.