Aplicación Híbrida con Verificación: Dos Reglas que Comparan el Texto con los Datos y el Tono de la Franja Media

Araceli Castillo

Maestría en Inteligencia Artificial, Atlantis University

MAI 540: Machine Learning

Prof. Kevin A. García Gallardo

15 de octubre de 2026

Aplicación Híbrida con Verificación: Dos Reglas que Comparan el Texto con los Datos y el Tono de la Franja Media

La aplicación de la Clase 7 combina un Random Forest que estima la probabilidad de crédito malo en German Credit (Hofmann, 1994), un modelo de lenguaje pequeño, Qwen2.5-0.5B-Instruct (Qwen Team, 2024), que la explica, y un verificador por reglas. En esta tarea comparé el predictor con una red neuronal, ejecuté la aplicación en mi Mac sobre 12 solicitudes, busqué los textos falsos que el verificador dejaba pasar y agregué dos reglas, cuyo efecto medí sobre exactamente los mismos textos.

La Red Neuronal Frente al Random Forest

Con la misma partición que entrenar_predictor (20 % de prueba, estratificada, semilla 42), la red tiene capas de 61, 16, 8 y 1 neuronas y aprendió 1,137 pesos. Ambos modelos aciertan el 100 % del entrenamiento, así que memorizan; lo que importa son las 200 solicitudes de prueba (Tabla 1). El Random Forest acierta 0.770 y la red 0.735, con un AUC de 0.812 frente a 0.744. La red detecta más créditos malos (53 % frente a 38 %), pero porque predice «malo» más veces (57 frente a 32), no porque distinga mejor: su AUC es menor. El bosque aprende reglas de corte sobre cada variable y las vota entre 200 árboles (Breiman, 2001); la red aprende una combinación continua de las 61 columnas codificadas, que no se puede leer como reglas. Para este problema elegiría el Random Forest: ordena mejor el riesgo y, como mostré en la Tarea 7.1, bajar su umbral a 0.30 detecta más malos sin cambiar de modelo.

La Aplicación sobre 12 Solicitudes

El verificador de clase rechazó 5 de 12 explicaciones. Tres por números inventados: la solicitud 2 calculó un «5 % del saldo total», la 5 dijo que la cuenta tenía «100 euros» y la 11 estimó un «interés anual de alrededor de $108», ninguno de ellos presente en los datos. Dos por tono: la solicitud 1, con 26 %, dijo que eso «es alto», y la 10, con 28 %, también. En los cinco casos se mostró el texto de respaldo.

Lo que la Verificación Dejaba Pasar

De los siete textos aprobados, cinco tenían errores. El más claro es la solicitud 8, con 43 % y estos datos: saldo negativo y vivienda alquilada. El texto afirma que la persona tiene «una cuenta corriente sin saldo negativo», lo contrario del dato, y que «la cuenta está alquilada», confundiendo la cuenta con la vivienda. Pasó porque el verificador de clase solo compara números y nunca lee lo que el texto dice de la cuenta. La solicitud 3 repite el error de «sin saldo negativo» con 56 %. La solicitud 4 reproduce el caso de clase: afirma que el cliente es «una persona sola», un dato que no existe. Además, las solicitudes 4, 7, 8 y 12 califican de «alto» un riesgo de entre 36 % y 43 %, la franja que verificar_tono no revisa.

Dos Reglas Nuevas

La primera regla, verificar_datos, compara el texto con los datos: si menciona una cuenta corriente o una vivienda distinta de la del dato, si niega el saldo negativo cuando el dato lo afirma, o si menciona rasgos que la solicitud no trae (estado civil, empleo, ingresos o salud). La segunda, verificar_tono_medio, rechaza «alto», «bajo», «elevado» o «mínimo» cuando la probabilidad está entre 30 % y 60 %, las mismas franjas del texto de respaldo. Ambas usan límites de palabra para que «bajo» no coincida dentro de «trabajo». Escribí cuatro pruebas con los textos reales de las solicitudes 4, 8 y 12; con el verificador de clase las cuatro fallan y con las reglas pasan. Las cinco pruebas originales siguen pasando, y el total es de 13.

Efecto y Falsos Positivos

Sobre los mismos 12 textos, los rechazos pasaron de 5 a 10 (Tabla 2). La regla de datos atrapó las solicitudes 3, 4 y 8, y la de tono medio, seis. Para medir falsos positivos usé los 200 textos de respaldo, que son correctos por construcción: ninguno fue rechazado. Sí encontré uno al escribir las pruebas: «un riesgo medio, no alto» se rechazaba porque contiene «alto». Lo corregí ignorando los extremos precedidos de «no», «no es» o «ni», y la prueba quedó en el repositorio. Hay además dos rechazos discutibles: las solicitudes 7 y 12 solo fallan por llamar «alto» a 36 % y 37 %. Si la tasa base es 30 %, ese riesgo está por encima del promedio,

y la franja de 30 % a 60 % es una convención mía, no un hecho. Para ajustarlo aceptaría comparaciones explícitas como «mayor que el promedio» en vez de prohibir la palabra.

Límites y Recomendación

Las dos solicitudes que siguen pasando tampoco son impecables. Hablan de «euros», cuando el dataset no tiene moneda. La solicitud 6 concluye que hay «una situación financiera sostenible» sin ningún dato que lo respalde, y la 9 dice que la cuenta «se considera alquilera». Las reglas comparan palabras, no significados. «La cuenta está alquilada» pasa porque «alquilada» coincide con el dato aunque se atribuya a la cuenta; una paráfrasis como «riesgo mayor» o «números negativos» se escapa; y una afirmación causal falsa, como que la vivienda propia «puede aumentar» el riesgo (solicitud 5), no tiene ninguna palabra que la delate. El lenguaje admite infinitas formas de decir algo falso, y una lista de reglas solo cubre las que ya se vieron (Ji et al., 2023). Por eso no recomendaría a un banco mostrar el texto libre a un cliente. Recomendaría mostrar por defecto el texto de respaldo, armado solo con datos; usar el modelo de lenguaje solo para redactar sobre una plantilla con los datos ya fijados; y enviar a revisión humana toda explicación de un rechazo de crédito y toda solicitud de la franja media, donde el verificador encuentra más errores. En Estados Unidos, además, la Regulación B exige comunicar razones específicas al negar un crédito (12 C.F.R. § 1002.9), y un texto que inventa razones es un riesgo legal, no solo técnico.

Referencias

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Equal Credit Opportunity Act (Regulation B), 12 C.F.R. § 1002.9 (2024).

Hofmann, H. (1994). *Statlog (German credit data)* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5NC77

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, *55*(12), Artículo 248. https://doi.org/10.1145/3571730

Qwen Team. (2024). *Qwen2.5 technical report* (arXiv:2412.15115). arXiv. https://doi.org/10.48550/arXiv.2412.15115

Tabla 1

Red Neuronal y Random Forest sobre las Mismas 200 Solicitudes de Prueba

Modelo	Exactitud entren.	Exactitud prueba	AUC	Malos detectados	Predice «malo»
Red neuronal (61-16-8-1, 1,137 pesos)	1.000	0.735	0.744	0.533	57
Random Forest (200 árboles)	1.000	0.770	0.812	0.383	32

Nota. Partición 80/20 estratificada, semilla 42. Las dos predicen lo mismo en el 78 % de las solicitudes. Referencia «siempre bueno»: 0.700.

Tabla 2

Rechazos de la Verificación Antes y Después de las Reglas Nuevas, sobre los Mismos 12 Textos

Sol.	Prob.	Antes	Después	Motivo del rechazo
1	26 %	Rechaza	Rechaza	Tono bajo («alto» con 26 %)
2	25 %	Rechaza	Rechaza	Número inventado (5 %)
3	56 %	Pasa	Rechaza	Niega el saldo negativo; «alto» en franja media
4	41 %	Pasa	Rechaza	«Persona sola» sin dato; «alto» en franja media
5	42 %	Rechaza	Rechaza	Número inventado (100); «alto» en franja media
6	20 %	Pasa	Pasa	— («situación sostenible» y «euros» sin dato)
7	36 %	Pasa	Rechaza	«Alto» en franja media (discutible)
8	43 %	Pasa	Rechaza	Niega el saldo negativo; «alto» en franja media
9	40 %	Pasa	Pasa	— («se considera alquilera», atribuido a la cuenta)
10	28 %	Rechaza	Rechaza	Tono bajo («alto» con 28 %)
11	4 %	Rechaza	Rechaza	Número inventado (108)
12	37 %	Pasa	Rechaza	«Alto» en franja media (discutible)
Total		**5 de 12**	**10 de 12**	Falsos positivos en 200 textos de respaldo: 0

Nota. Textos generados una sola vez en mi Mac con Qwen2.5-0.5B-Instruct (do_sample=False) y verificados de nuevo con medir_rechazos.py. Por regla, después: números 3, tono bajo/alto 2, texto contra datos 3, tono medio 6.